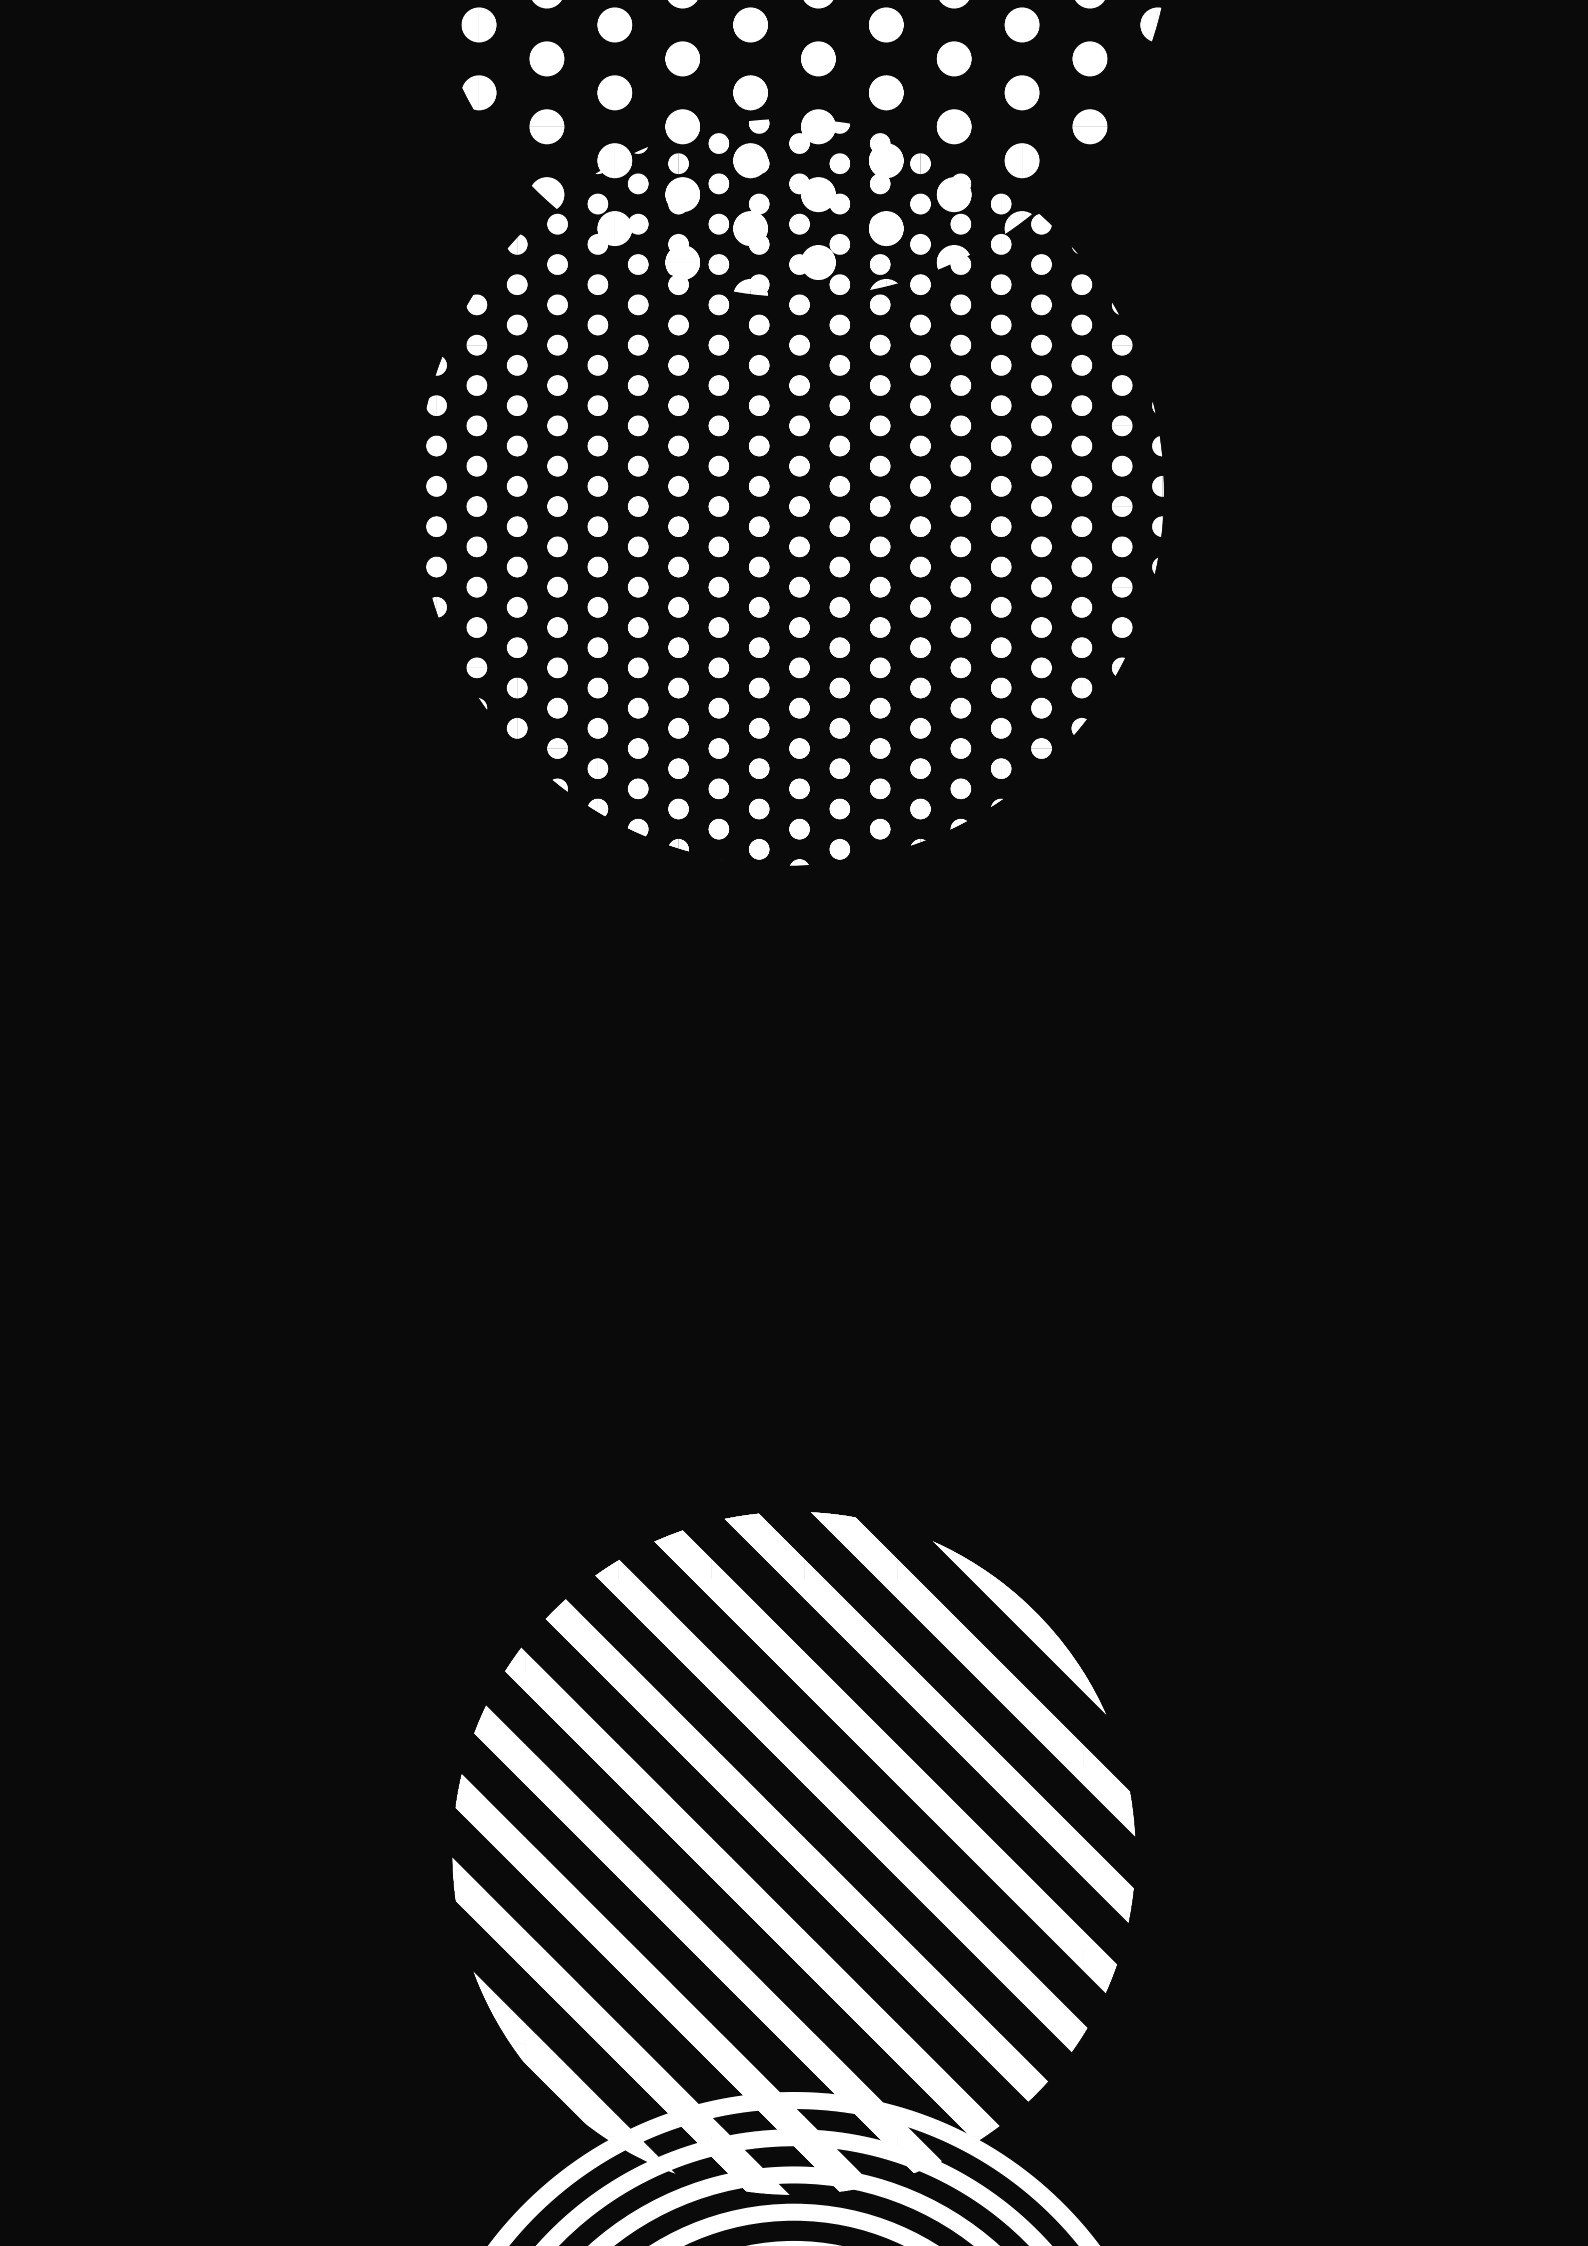

참고 http://taewan.kim/post/cnn/

CNN - Convolutional Neural Network

MLP의 Fully Connected Layer는 1차원배열 => 공간정보유실 -> 정보부족, 비효율, 정확도↓

if image (?, ?, 3) -> (n, ?×?×3)

· CNN은 공간정보 유지한 상태로 학습

- 마지막에 Fully Connected
  why? 클래스 분류 해줘야해

- Fully Connected와 다른 점
  · 입출력 데이터 형상유지
  · 공간정보 유지, 인접이미지 특징인식
  · 복수필터, Pooling Layer
  · 학습 파라미터 적음

· Conv layer n개 filter면
  출력은 n개 채널

· filter는 입력채널수 맞춰서
  1개의 필터맵 반환

· Padding - 사이즈 조절, 외곽인식

· Pooling - 출력사이즈감소, 데이터강조
  · 학습파라미터X, 크기 감소, 채널그대로

∴ Global한 feature

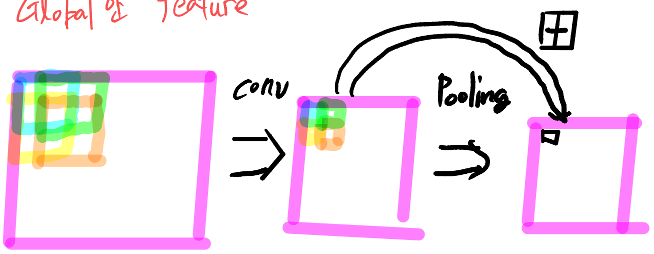

. more deep, low parameter

ALEX Net

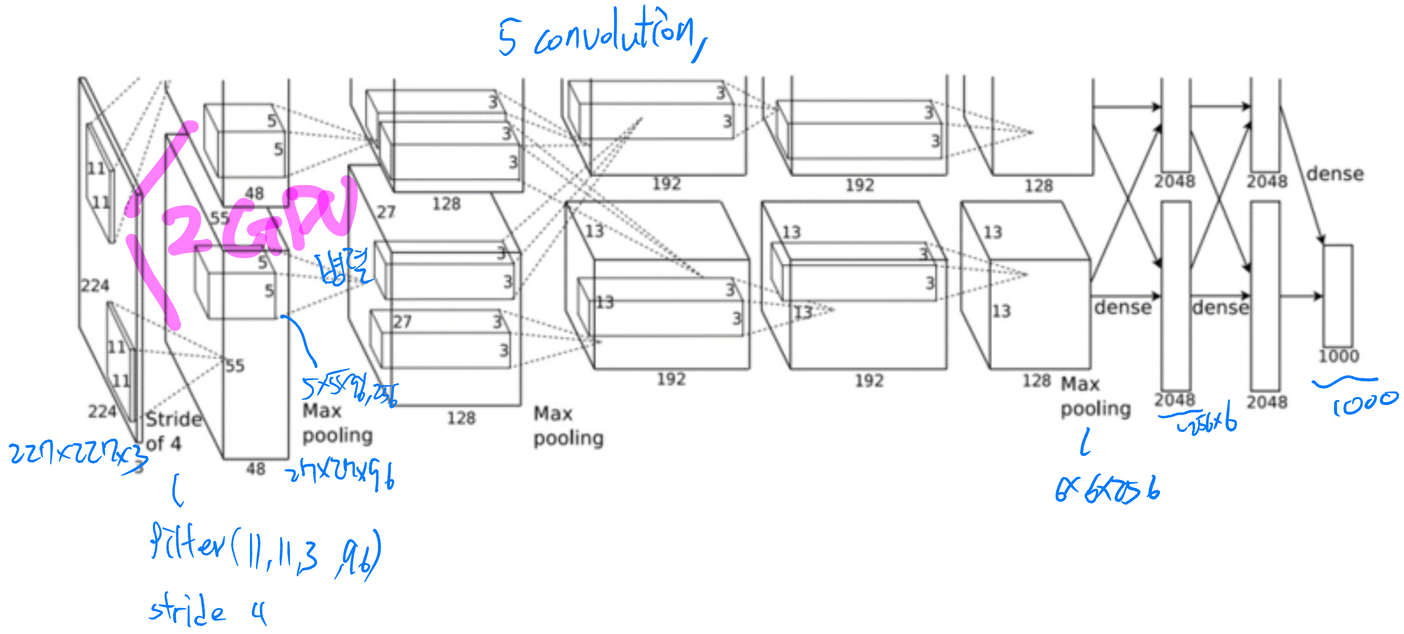

2개 GPU, 성능, 속도

1. ReLU - 빠른 학습 sigmoid, tanh
2. Normalizatin
3. Overlapping Pooling 3×3, 2strid
4. Data Augmentation - overfitting 억제 위해
   1. 256 → 227 crop 2. RGB변화
5. Dropout

GoogLeNet

Inception

\- Layer 추가 — 문제점: Overfitting, 연산량 증폭

∘ NIN (Network In Network)

VGGNet

· 단일네트워크에서 Convolution의 개수↑

convolu 3×3, padding1, ·

resize는 maxpooling으로만

5×5 3×3 2개 같은size

But Parameter↓,

more nonlinearity

· 16~19 layer에서 정확도가 내려가

↳ 이를 어느정도 극복한게 Resnet

∴ 단순하고 성과가 좋아서 많이 사용됨

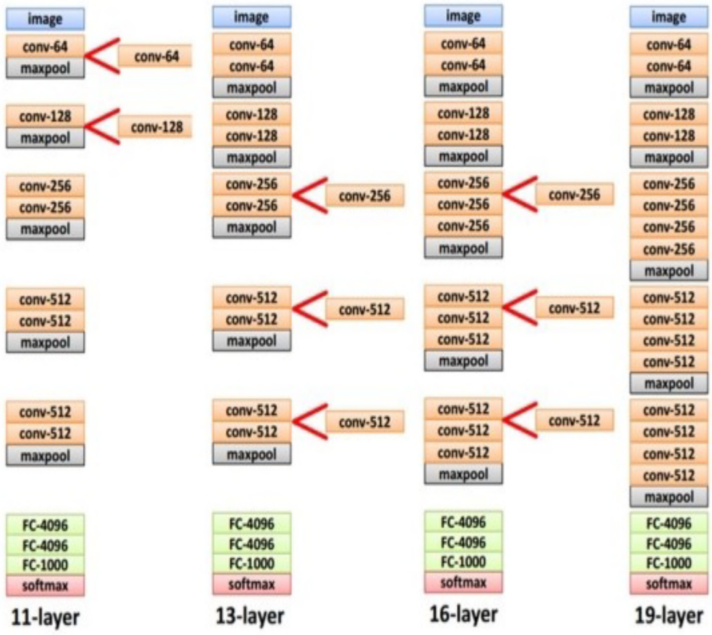

ResNet

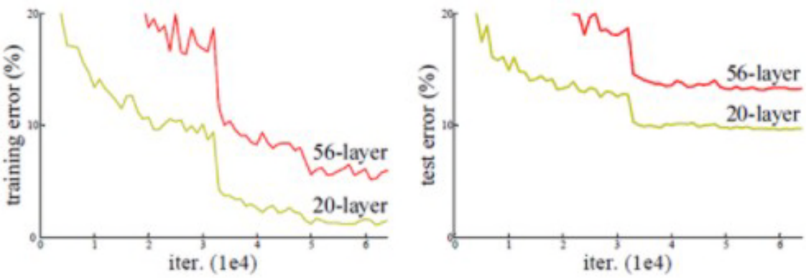

layer가 깊어져
· gradient vanishing

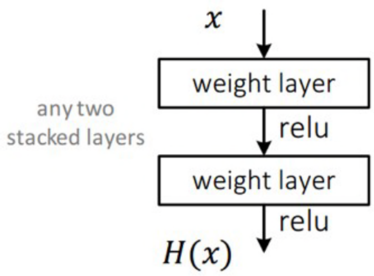

평범CNN은
$H(x) = conv(conv(x))$
Convolution Layer 2번
$H(x)$ 얻기위한 학습

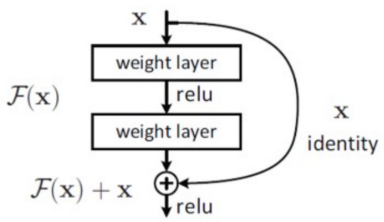

Resnet have "skip connection"
$H(x) = f(x) + x$
아웃풋에 그 전 결과 더하고 relu
$f(x) \approx 0$ 이 되는 학습
나머지 (residual)

· x 더하기 ⇒ 연산증가X

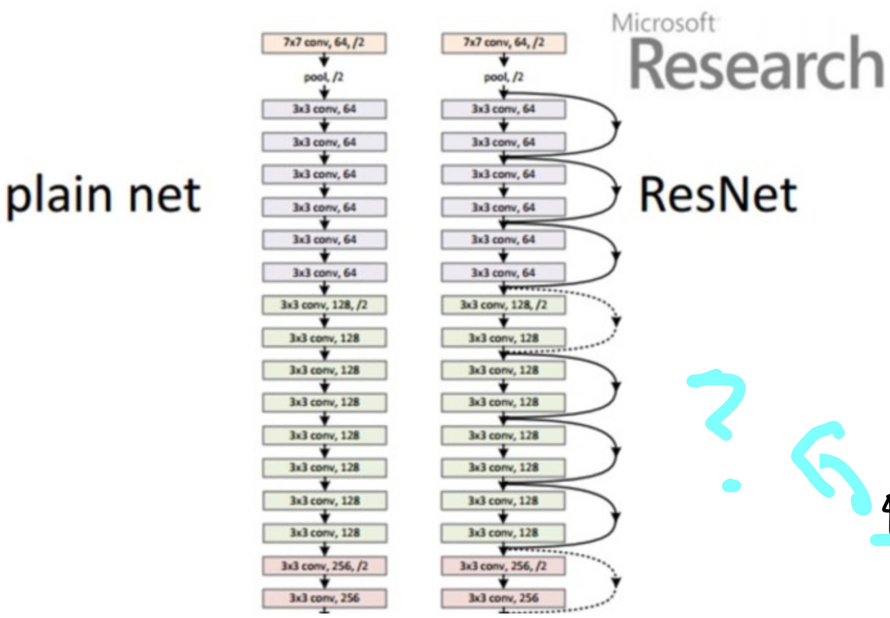

?

특징
1. 3x3 filter
2. 복잡도 위해, max pool
   hidden fc, dropout X
3. 출력 feature map 크기 같으면
   동일한 filter
4. 출력 feature map 절반시, 연산량보존위해
   filter 2배로
5. feature map 줄일때
   pooling 대신, stride 2

출력결과

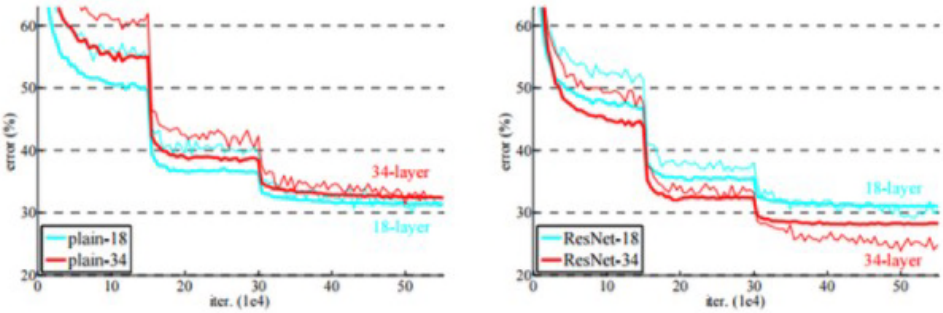

$$x_{l+1} = x_l + F(x_l)$$

$$x_{l+2} = x_{l+1} + F(x_{l+1})$$

$$= x_l + F(x_l) + F(x_{l+1})$$

$$x_L = x_l + \sum_{i=l}^{L-1} F(x_i)$$

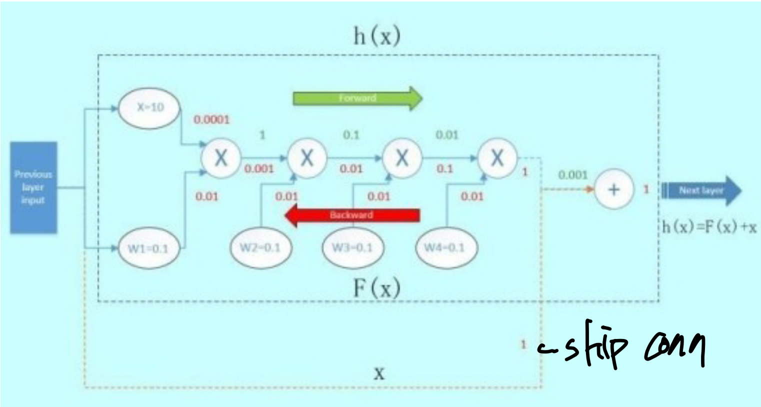

(How to avoid vanishing)

[0.0001, 0.01] → [1, 0.0001, 0.01]

1이라는 gradient 추가

because relu $dh(x)/dx = 1$

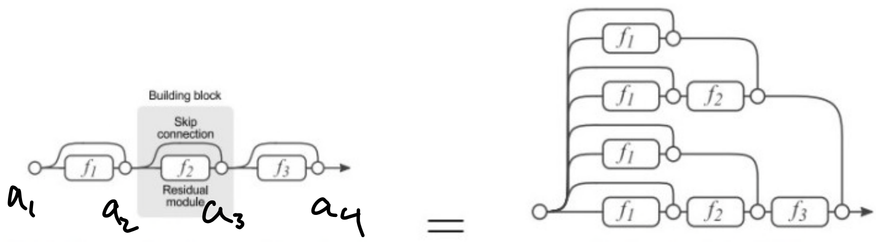

(a) Conventional 3-block residual network

(b) Unraveled view of (a)

$$x_L + \sum_{i=l}^{L-1} f(x_i)$$

$f(1) = conv(a_1)$

a_1

$a_2 = a_1 + f(1)$

$f(2) = conv(a_2)$

$= conv(a_1 + f_1)$

$a_3 = a_2 + f_2$

$f(3) = conv(a_3)$

$= conv(a_2 + f_2)$

$= conv(a_1 + f_1 + f_2)$

$a_4 = a_3 + conv(a_1 + f_1 + f_2)$

$= a_1 + f_1 + f_2$

⇒ a_1을 network 영향

layer가 삭제되도 가능